



الجمهورية العربية السورية

وزارة التعليم العالي

جامعة اللاذقية _ كلية الهندسة المعلوماتية

قسم الذكاء الصناعي

توليد وصف للصور باستخدام نموذج ذكاء صناعي يعتمد على بنية المحوّل (Transformer)

Generating image description using an artificial intelligence model based on the Transformer architecture.

مشروع فصلي

إعداد الطلاب

يزن حسن بلال

ماجد حسين حجيرة

إشراف

الدكتور محمد ماشي

2025-2024

الفصل الأول: المقدمة

ملخص

يهدف هذا المشروع إلى تطوير نظام توليد أوصاف نصية تلقائية للصور بالاعتماد على تقنيات الذكاء الصناعي والتعلم العميق، باستخدام بنية المحوّل (Transformer) ضمن نموذج ترميزي - فك ترميز (Vision Encoder-Decoder) يعتمد على Vision Transformer (ViT) كمشفّر و GPT-2 كفك ترميز. تم استخدام مجموعة بيانات MS-COCO 2017 التي تتضمن صوراً متنوعة مع أوصاف نصية متعددة، حيث جرى إجراء معالجة مسبقة للصور عبر تغيير أبعادها وتطبيعها وتحويلها إلى تمثيلات مناسبة للنموذج، كما تم ترميز النصوص باستخدام Tokenizer خاص بـ GPT-2 مع إزالة التكرارات لتحسين جودة التدريب. تم تدريب النموذج باستخدام خوارزمية الانحدار العكسي وتقنية تحسين المعلمات AdamW Optimizer مع تطبيق آليات تنظيم مثل Dropout و Cosine Annealing لضبط معدل التعلم، إضافة إلى اعتماد Gradient Accumulation لتحسين الاستقرار. أثناء عملية التوليد، تم تطبيق Beam Search مع قيود مثل no-repeat n-gram و repetition penalty للحصول على أوصاف أكثر دقة وتنوعاً. جرى تقييم النموذج باستخدام مقاييس كمية معيارية تشمل BLEU و ROUGE-L و METEOR ودقة التطابق بين الكلمات المرجعية والمولدة، حيث أظهرت النتائج قدرة النموذج على توليد أوصاف متماسكة وذات صلة بالمحتوى البصري للصور في بيانات التحقق والاختبار. تشير هذه النتائج إلى إمكانية اعتماد النظام في تطبيقات عملية مثل الأرشفة الرقمية الذكية، ودعم ذوي الاحتياجات الخاصة عبر القراءة الآلية للصور، وتحسين أداء محركات البحث المرئية في أنظمة المعلومات الحديثة.

This project aims to develop an **automatic image captioning system** that generates descriptive text for images using **artificial intelligence and deep learning techniques**. The system is built on a **Transformer-based Vision Encoder-Decoder architecture**, employing a **Vision Transformer (ViT)** as the encoder and **GPT-2** as the decoder. The model is trained on the **MS-COCO 2017 dataset**, which contains a large collection of diverse images paired with multiple human-written captions. Preprocessing steps included resizing and normalizing the images to make them suitable for the encoder, as well as tokenizing the captions using a **GPT-2 tokenizer** and removing repetitive tokens to improve training quality. Model training was carried out using **backpropagation** and the **AdamW optimizer**, combined with regularization techniques such as **Dropout** and **Cosine Annealing** learning rate scheduling. **Gradient accumulation** was applied to stabilize training with larger effective batch sizes. During inference, **Beam Search** with **no-repeat n-gram constraints** and a **repetition penalty** was used to enhance the fluency and diversity of the generated captions. The model was evaluated using standard quantitative metrics including **BLEU**, **ROUGE-L**, **METEOR**, and a custom token-overlap accuracy score. Results demonstrate that the proposed system is capable of producing coherent and semantically relevant captions for images in both validation and test sets. These findings highlight the potential of this approach for practical applications such as **intelligent digital archiving**, assisting **visually impaired users** through automated image descriptions, and improving the performance of **image-based search engines** in modern information systems.

الفهرس

2..... الفصل الأول: المقدمة

ملخص	3
مقدمة	7
أهداف المشروع	8
1.1 الهدف الرئيسي	8
1.2 الأهداف الفرعية	8
1.2.1 تحضير البيانات ومعالجتها:	8
1.2.2 تصميم النموذج الرياضي والمعماري:	8
1.2.3 تنفيذ وتدريب النموذج عملياً:	9
1.2.4 تحسين جودة التوليد النصي:	9
1.2.5 تقييم النموذج كمياً:	9
1.2.6 تحليل النتائج وتقديم التوصيات:	9
منهجية الدراسة	10
الدراسة المرجعية	11
1. الأساليب التقليدية:	11
2. مرحلة الشبكات العصبية الالتفافية (CNN) والشبكات المتكررة (RNN)	11
3. مرحلة النماذج الهجينة Encoder–Decoder مع Attention	11
4. مرحلة المحولات (Transformers)	11
5. النماذج الموحدة: Vision Encoder–Decoder	11
6. استطلاع حول تجزئة مشيل الكائن: A Survey on Object Instance Segmentation	12
7.	13

13..... and CNN Automatic Arabic Image Captioning Using RNN-LSTM-Based Language Model

14 جدول الأشكال

15 جدول الاختصارات

16..... الفصل الثاني: القسم النظري

17 2.1 مكونات الشبكات العصبية:.....

18 2.2 الشبكات العصبية العميقة.....

18 2.3 الشبكات الالتفافية (CNN).....

19 2.4 الشبكات المتكررة (RNN).....

19 2.5 آلية الانتباه (Attention Mechanism).....

20 2.6 بنية المحول (Transformer).....

21 2.7 المحولات البصرية (Vision Transformer – ViT).....

22 2.8 الترميز النصي باستخدام GPT-2 Tokenizer.....

22 الشكل 2.4 : الترميز النصي باستخدام GPT-2 Tokenizer.....

22 2.9 خوارزمية Beam Search.....

23 2.10 الخلاصة النظرية.....

24..... الفصل الثالث: القسم العملي

25 3.1 المقدمة العملية

25 3.2 إعداد البيئة وتنصيب المكتبات.....

26 3.3 تحميل وإعداد البيانات

26 3.4 المعالجة المسبقة

27 3.5 بناء مجموعة البيانات و DataLoader.....

28 3.6 تصميم النموذج

29.....	3.7 إعداد بيئة التدريب (معدل)
	3.8 حلقة التدريب والتحقق 30
	3.9 التوليد والاستدلال 31
	3.10 التقييم الكمي ا 31
32.....	3.11 حفظ واسترجاع النموذج
33.....	3.12 نتائج التدريب والتحقق:
	3.13 نتائج الاختبار 34
	3.14 الخاتمة العملية 35
36.....	المراجع

مقدمة

شهد مجال الذكاء الصناعي والتعلم العميق في العقد الأخير تطوراً ملحوظاً، انعكس بشكل مباشر على مجموعة واسعة من التطبيقات العملية التي تمس الحياة اليومية. ومن بين هذه التطبيقات المهمة يبرز مجال التوصيف التلقائي للصور (Image Captioning) ، الذي يجمع بين معالجة الصور ومعالجة اللغات الطبيعية في إطار واحد، ويهدف إلى تمكين الحاسوب من إنتاج أوصاف نصية دقيقة وذات معنى لمحتوى الصور.

تتجلى أهمية هذا المجال في كونه يشكل حلقة وصل بين الرؤية الحاسوبية واللغة، مما يسمح بابتكار أنظمة قادرة على تحسين إمكانية الوصول (Accessibility) لذوي الاحتياجات الخاصة، وتطوير أنظمة أرشفة واسترجاع ذكية للصور، وتعزيز أداء محركات البحث المعتمدة على المحتوى البصري. في المراحل الأولى، اعتمدت الحلول التقليدية لتوصيف الصور على النماذج الإحصائية وخوارزميات مطابقة الأنماط، إلا أن هذه الأساليب لم تحقق الدقة المطلوبة بسبب محدودية قدرتها على تمثيل العلاقات المعقدة بين العناصر البصرية واللغوية. مع ظهور الشبكات العصبية العميقة (Deep Neural Networks) ، وخصوصاً الشبكات الالتفافية (CNN) لمعالجة الصور و الشبكات المتكررة (RNN, LSTM, GRU) لمعالجة النصوص، شهد هذا المجال تقدماً كبيراً، لكن القيود المرتبطة بالتوازي الحسابي وصعوبة معالجة التبعيات طويلة المدى في النصوص دفعت الباحثين إلى استكشاف نماذج أحدث، أحدث ظهور بنية المحول (Transformer) تحولاً جذرياً في مجال معالجة اللغات الطبيعية، حيث أثبتت فعاليتها في تمثيل السياقات الطويلة والتوازي في التدريب. لاحقاً، امتدت هذه البنية إلى مجال الرؤية الحاسوبية من خلال المحول البصري (Vision Transformer – ViT) ، الذي يقوم بتقسيم الصورة إلى رقع صغيرة (Patches) ومعالجتها بطريقة مشابهة لمعالجة تسلسلات النصوص. هذا الدمج بين ViT و المحول اللغوي في إطار Encoder–Decoder أتاح بناء أنظمة قادرة على تحقيق نتائج متقدمة في مهام توصيف الصور.

بناءً على ما سبق، يأتي هذا المشروع كخطوة عملية نحو تصميم وتنفيذ نموذج توليد أوصاف نصية للصور باستخدام بنية Vision Encoder–Decoder بالاعتماد على مكتبات PyTorch و Transformers، وتدريبه على مجموعة بيانات COCO 2017. يسعى المشروع إلى تقديم نموذج قادر على إنتاج أوصاف دقيقة وذات معنى للصور، مع تقييم أدائه باستخدام مقاييس كمية معيارية مثل BLEU و ROUGE والدقة، وصولاً إلى تحليل النتائج ومناقشة سبل تحسينها في المستقبل.

أهداف المشروع

1.1 الهدف الرئيسي

يتمثل الهدف الأساسي من هذا المشروع في تطوير نموذج ذكي قادر على توليد أوصاف نصية دقيقة وذات معنى للصور الرقمية، وذلك بالاعتماد على بنية المحول (Transformer) في إطار Vision Encoder–Decoder، وتدريبه على مجموعة بيانات معيارية عالمية (COCO 2017)، بما يحقق تكاملاً فعالاً بين الرؤية الحاسوبية ومعالجة اللغات الطبيعية.

1.2 الأهداف الفرعية

يندرج تحت هذا الهدف العام مجموعة من الأهداف الفرعية التي تسهم في إنجاح المشروع، وهي:

1.2.1 تحضير البيانات ومعالجتها:

تحميل مجموعة البيانات (COCO 2017) وتنظيمها ضمن بيئة العمل.

أخذ عينة من البيانات (50 ألف صورة للتدريب و2000 صورة للتحقق) نظراً لمحدودية الموارد الحسابية.

تطبيق عمليات المعالجة المسبقة للصور (تغيير الأبعاد إلى 224×224 ، التحويل إلى Tensor، القلب الأفقي العشوائي بنسبة 50%).

إجراء المعالجة اللغوية للنصوص باستخدام GPT-2 Tokenizer مع آليات الحشو والاقطاع بطول أقصى 32 توكن واختيار تعليق عشوائي لكل صورة.

1.2.2 تصميم النموذج الرياضي والمعماري:

استخدام نموذج جاهز VisionEncoderDecoder من مكتبة HuggingFace باسم `.nlconnect/vit-gpt2-image-captioning`.

يتكون النموذج من:

Transformer Encoder (ViT-B/16) لمعالجة الصور (12 طبقة Transformer - مع 12 رأس Attention).

GPT-2 Decoder لمعالجة النصوص وتوليد العبارات (12 طبقة Transformer).

دمج الوحدتين في بنية متكاملة Vision Encoder-Decoder Model.

1.2.3 تنفيذ وتدريب النموذج عملياً:

استخدام خوارزمية الانحدار العكسي مع AdamW Optimizer بمعدل تعلم منخفض (e-62) لضمان استقرار التدريب.

تطبيق جدولة معدل التعلم باستخدام CosineAnnealingLR لتخفيض معدل التعلم تدريجياً.

تطبيق آليات تنظيم مثل Augmentation (قلب الصور) لتقليل فرط التكيف.

اعتماد Mixed Precision Training مع GradScaler لتسريع التدريب.

استخدام Gradient Accumulation كل 4 خطوات لتحسين استغلال الذاكرة مع دفعات صغيرة.

1.2.4 تحسين جودة التوليد النصي:

ق خوارزمية Beam Search بحجم حزمة 5 لزيادة دقة وتنوع الأوصاف المولدة.

1.2.5 تقييم النموذج كمياً:

حساب مقاييس الأداء BLEU، ROUGE-L، METEOR، والدقة (Accuracy).

تسجيل هذه القيم لكل حقبة ورسم المنحنيات

1.2.6 تحليل النتائج وتقديم التوصيات:

مناقشة التحديات مثل قلة البيانات المستخدمة 50k صورة فقط للتدريب و2000 للتحقق وتأثيرها على المقاييس.

اقتراح حلول مثل زيادة حجم البيانات وعدد الحقبات أو استخدام Fine-tuning على نماذج مدربة مسبقاً.

منهجية الدراسة

بيئة العمل والأدوات المستخدمة

تم تنفيذ المشروع في بيئة حوسبة سحابية تعتمد على معالجات رسومية (GPU) تدعم مكتبات CUDA لتسريع عمليات التدريب. وقد تم استخدام حزمة من الأدوات والبرمجيات مفتوحة المصدر، يمكن تلخيصها فيما يلي:

❖ لغة البرمجة Python:، لما توفره من مكتبات متخصصة في الذكاء الصناعي والتعلم العميق.

❖ المكتبات الأساسية:

- PyTorch : إطار عمل للتعلم العميق يوفر مرونة عالية في بناء النماذج وتنفيذ عمليات التدريب.
- TorchVision : مكتبة داعمة لمعالجة الصور وتحميل مجموعات البيانات القياسية.
- Transformers (HuggingFace) : مكتبة متقدمة لتطبيق نماذج المحولات (Transformers) في مجالات النصوص والرؤية.
- NLTK و ROUGE-Score : أدوات لتقييم جودة النصوص المولدة عبر مقاييس BLEU و ROUGE.
- Pycocotools : مكتبة خاصة للتعامل مع مجموعة بيانات COCO وتسهيل عمليات التحميل والتقييم.

❖ مجموعة البيانات COCO 2017 Dataset : والتي تعد من أشهر المجموعات العالمية في مهام توصيف الصور، حيث تحتوي على مئات آلاف الصور مع أوصاف نصية متعددة لكل صورة.

❖ البيئة التجريبية: تم الاعتماد على بيئة Google Colab كمنصة للتدريب، لما توفره من وحدات معالجة رسومية، مع تخزين البيانات والنماذج عبر Google Drive.

❖ إن مجموعة البيانات COCO 2017 تحتوي على بيانات الاختبار ولكن لا تحتوي على تعليقات لكي نستخدمها يجب أن نرسل الصور مع التعليقات التي قمنا بتوليدها بالنموذج الخاص بنا إلى خادم الخاص بموقع COCO ولكن لم نستطع القيام بذلك، لذلك قمنا بالحصول على مجموعة بيانات تحتوي على 4444 صورة مع أوصاف وقمنا باعتبار أنها البيانات الذي سوف نختبر النموذج عليها ونقوم بتقييمه.

الدراسة المرجعية

إن اختيار البنية المعتمدة في هذا المشروع جاء نتيجة مراجعة للأبحاث السابقة والتطورات العلمية في مجال توصيف الصور. يمكن تلخيص السياق التاريخي والمرجعي على النحو الآتي:

1. **الأساليب التقليدية:** اعتمدت في البداية على تقنيات الرؤية الحاسوبية الكلاسيكية وخوارزميات التعلم الآلي (الإشرافية) مثل SVM ، (KNN لربط الميزات المستخرجة من الصور مع جمل نصية محدودة. إلا أن هذه الأساليب كانت محدودة وغير قادرة على تمثيل العلاقات المعقدة بين العناصر البصرية والنصية.

2. **مرحلة الشبكات العصبية الالتفافية (CNN) والشبكات المتكررة (RNN)**

○ استُخدمت CNN لاستخلاص الميزات البصرية من الصور، بينما وظّفت RNN / LSTM لتوليد الجمل النصية كلمة بكلمة.

○ من أشهر النماذج (Show and Tell (Google, 2015) و Show, Attend and Tell الذي أدخل آلية الانتباه (Attention) لتحسين جودة الأوصاف.

3. **مرحلة النماذج الهجينة Encoder-Decoder مع Attention:**

○ تم دمج CNN كـ Encoder و LSTM كـ Decoder مع آلية Attention ، مما مكّن النموذج من التركيز على أجزاء مختلفة من الصورة أثناء التوليد.

○ هذه المقاربة حسّنت النتائج لكنها واجهت تحديات في التوازي الحسابي ومعالجة التبعيات الطويلة في النصوص.

4. **مرحلة المحولات (Transformers):**

○ أحدثت ورقة (Attention Is All You Need (Vaswani et al., 2017) نقلة نوعية في معالجة اللغات الطبيعية عبر استبدال البنى المتكررة بآليات الانتباه الذاتي.

○ لاحقاً، تم اقتراح Vision Transformer (ViT, Dosovitskiy et al., 2020) لمعالجة الصور من خلال تقسيمها إلى رقع ومعالجتها كتسلسل.

5. **النماذج الموحدة: Vision Encoder-Decoder:**

○ الدمج بين ViT و Transformer Decoder أتاح بناء أنظمة قوية في توصيف الصور،

مثل OSCAR و VinVL و BLIP.

○ هذه النماذج شكلت الدافع لاعتماد البنية نفسها في مشروعنا، مع تعديلها لتلائم بيئة التدريب

والموارد المتاحة.

6. استطلاع حول تجزئة مثيل الكائن: A Survey on Object Instance Segmentation

❖ تقنية تجزئة المثل، وهي مجال رئيسي في رؤية الكمبيوتر والتي تجمع بين اكتشاف الكائنات

والتجزئة الدلالية لتحديد مواقع الكائنات وحوافها بدقة على مستوى البكسل .

❖ تركز الورقة على التقنيات القائمة على التعلم العميق، التعلم المعزز، والمحولات

❖ النقاط الرئيسية:

■ تعريف تجزئة المثل:

- تتجاوز اكتشاف الكائنات والتجزئة الدلالية، حيث تحدد وتصنف كل كائن في

الصورة أو الفيديو مع تحديد حدوده بدقة.

- تستخدم في تطبيقات مثل الروبوتات، الرعاية الصحية، القيادة الذكية، المراقبة

بالفيديو، والتفاعل بين الحاسوب والإنسان.

■ التقنيات المستخدمة:

- التعلم العميق:

➤ يشمل أساليب قائمة على الاقتراح (proposal-based) باستخدام المربع المحيط

للكشف عن الكائنات ثم تجزئتها، وهي تستغرق وقت طويل ومعقدة.

➤ الأساليب الخالية من الاقتراح (proposal-based) تعتمد على التجميع على

مستوى البكسل، وهي أبسط وأكثر كفاءة.

- التعلم المعزز (RL):

➤ مجال ناشئ يظهر نتائج واعدة، لكنه يواجه تحديات مثل تعقيد مساحة الحالة.

➤ قليل من الأبحاث استكشفت استخدامه في تجزئة المثل.

- المحولات (Transformers):

◆ أظهرت نجاحًا كبيرًا في معالجة اللغة الطبيعية وتُطبق الآن في رؤية الكمبيوتر،

مع أداء واعد في تجزئة المثل، التعرف على الصور، واكتشاف الكائنات

■ التحديات:

- التعامل مع الكائنات الصغيرة، تدهور الصور، وتقدير العمق.

- الحاجة إلى بيانات تدريب كبيرة في التعلم العميق.

❖ الاستنتاجات:

■ توفر المقالة نظرة شاملة على تقنيات تجزئة المثل، مع التركيز على التعلم

العميق، التعلم المعزز، والمحولات.

■ أظهر العمل الأخير نجاحًا كبيرًا باستخدام تقنيات المحولات التي تتغلب على

التقنيات الحالية من حيث الدقة والسرعة.

- تُبرز المقالة التقدم الكبير في هذا المجال ، مع الإشارة إلى التحديات المستمرة مثل التعامل مع البيانات المعقدة والحاجة إلى دقة أعلى، تُد المقالة مرجع قيماً للباحثين، حيث تقدم مفاهيم جديدة لاستكشاف التطورات المستقبلية.

.7

Automatic Arabic Image Captioning Using RNN-LSTM-Based Language Model and CNN

❖ ملخص:

- بناء نموذج ذكاء اصطناعي قادر على توصيف الصورة باللغة العربية بالإضافة للغة الإنكليزية.
- لذلك تم تطوير نموذج دمج توليدي للتعليق على الصور العربية اعتمد نموذج RNN-LSTM العميق ونموذج الـ CNN.
- تم تحديد التعليق على الصورة على انه مهمة تربط بين النموذج البصري ونموذج اللغة الطبيعية.
- يتكون من شبكتين:
 1. RNN: شبكة عصبية متكررة عميقة للجمل.
 2. CNN: شبكة عصبية تلافيفية عميقة للصور.
- تتفاعل معاً في طبقة الدمج لتوليد وتحليل التسمية.
- في الآونة الأخيرة في مجال توليد التعليقات توصلوا إلى نهج البناء ، يقوم النهج تدريجياً بإنشاء تعليق جديد لكل صورة ، وتنقسم إلى (CV/NLG) أو CNN/RNN .
- تم تقديم نموذج التعليق التوضيحي للصور العصبية (Neural Image Caption (NIC
- تبدأ العملية بتفكيك الصورة المدخلة عن طريق اكتشاف الكائنات ومناطق الاهتمام الأخرى لإنتاج تمثيل ناقل ، تتكون الشبكة العصبية التسلسلية الهرمية من مستويين:
 1. شبكة عصبية تسلسلية للجمل.
 2. شبكة عصبية تسلسلية للكلمات.
- الفئة الثانية هي نموذج الدمج الذي يتم فيه تعلم ميزات الصورة والنماذج اللغوية بشكل مستقل ثم دمجها في نموذج تغذية أمامية يحدث فيه التنبؤ.
- تم تقديم موصف التركيب العميق (DCC) ، يستطيع (DCC) توليد جمل تصف الأشياء المقدمة في بيانات الصور غير المرتبطة ولكن غير موجودة في بيانات الصور والجمل المربوطة.
- معالجة التسمية التلقائية للصور باللغة العربية فقط باستخدام الشبكة العصبية المتكررة القائمة على جذر الكلمة RNN وشبكة DBN

جدول الأشكال

الصفحة	الوصف	رقم الشكل	القسم
14	آلية الانتباه	الشكل 2.1	النظري
15	بنية المحول (Transformer)	الشكل 2.2	
16	المحولات البصرية (Vision Transformer – ViT)	الشكل 2.3	
16	الترميز النصي باستخدام GPT-2 Tokenizer	الشكل 2.4	
17	خوارزمية Beam Search	الشكل 2.5	
20	عينات من بيانات COCO 2017 مع تعليقات مرجعية متعددة	الشكل 3.1	العملي
21	مخطط لأنبوب المعالجة المسبقة	الشكل 3.2	
22	بنية بيانات COCO في PyTorch	الشكل 3.3	
23	البنية المعمارية لنموذج Encoder-Decoder المعتمد.	الشكل 3.4	
24	إضافة الترميز الموضعي للرقع داخل Encoder.	الشكل 3.5	
25	آلية Beam Search في توليد النصوص.	الشكل 3.6	
26	منحنيات BLEU و ROUGE عبر الحقبات.	الشكل 3.7	
27	نتيجة بعد التدريب والتحقق	الشكل 3.8	
28	منحنيات loss و accuracy	الشكل 3.9	
28	نتائج الاختبار	الشكل 3.10	

جدول الاختصارات

الاختصار	المعنى
COCO	Common Objects in Context – مجموعة بيانات شهيرة لتوصيف الصور
ViT	Vision Transformer – المحوّل البصري لمعالجة الصور
GPU	Graphics Processing Unit – وحدة معالجة رسومية
NLTK	Natural Language Toolkit – مكتبة لمعالجة اللغات الطبيعية
JSON	JavaScript Object Notation – صيغة لتخزين البيانات
BLEU	Bilingual Evaluation Understudy – لتقييم جودة النصوص المولدة
ROUGE	Recall-Oriented Understudy for Gisting Evaluation – مقياس للتداخل النصي
METEOR	Metric for Evaluation of Translation with Explicit ORdering – مقياس جودة الترجمة
RNN	Recurrent Neural Network – الشبكات العصبية المتكررة
LSTM	Long Short-Term Memory – شبكات ذاكرة طويلة وقصيرة المدى
GRU	Gated Recurrent Unit – وحدة متكررة بوابات
CNN	Convolutional Neural Network – الشبكات العصبية الالتفافية
SVM	Support Vector Machine – آلة المتجهات الداعمة
KNN	K-Nearest Neighbors – خوارزمية الجيران الأقرب
GPT-2	Generative Pre-trained Transformer 2 – نموذج توليدي مدرب مسبقاً
AdamW	Adaptive Moment Estimation with Weight Decay – محسن تدريب مع تقليل الأوزان
LR	Learning Rate – معدل التعلم
Val Loss	Validation Loss – خسارة التحقق

الفصل الثاني: القسم النظري

2.1 مكونات الشبكات العصبية:

تتألف الشبكات العصبية من عدة مكونات، بالإضافة إلى بعض التقنيات التي قد تؤثر على مكوناتها وقد تختلف من شبكة لأخرى، ومن بين أشهر المكونات والتقنيات:

1. **(Neurons) العصبونات:** هي الوحدات الأساسية في الشبكات العصبية، وتستقبل البيانات من الطبقات السابقة، وتقوم بحساب الإشارة الصادرة عنها وإرسالها إلى الطبقات التالية.

2. **(Weights) الأوزان:** هي القيم التي تعبر عن قوة الصلة بين العصبونات المختلفة في الشبكة. تستخدم الأوزان للتحكم في الأثر الذي يتركه كل عصبون في النتيجة النهائية للشبكة.

3. **(Activation function) دالة التنشيط:** هي الدالة التي تطبق على إشارة الدخل للعصبون لإنتاج الإشارة النهائية. تستخدم دوال التنشيط لتحويل القيم الخام المستلمة من العصبون إلى قيم معينة تمثل الإشارة النهائية للعصبون.

4. **(Layers) الطبقات:** هي مجموعة من العصبونات التي تتصل ببعضها البعض وتعمل على معالجة البيانات.

5. **(Loss function) دالة الخسارة:** هي الدالة التي تحسب خطأ النموذج في التنبؤ بقيمة الخرج المطلوبة. تستخدم دوال الخسارة لتقييم أداء الشبكة وضبط قيم الأوزان والانحراف لتقليل الخطأ.

6. **(Optimizer) المحسن:** هو الخوارزمية التي تستخدم لتحسين أداء الشبكة من خلال ضبط قيم الأوزان والانحراف بناءً على نتائج دالة الخسارة. تشمل المحسنات الشائعة مثل Adam و SGD و RMSProp.

7. **(Regularization) التنظيم:** هي تقنية تستخدم لمنع الشبكة من الإفراط في التعلم عن البيانات التدريبية والتعامل مع البيانات الجديدة بشكل أفضل. تشمل تقنيات التنظيم مثل L1 و L2 و Dropout.

8. **(Convolution) التحويل:** تستخدم في الشبكات العصبية المتخصصة في معالجة الصور والفيديو.

9. **(Recurrent connections)** : تُستخدم في الشبكات العصبونية المتخصصة في معالجة البيانات الزمنية مثل الصوت والنص، حيث تسمح بتدفق المعلومات في الاتجاهين ولا تقتصر على الاتجاه الواحد كما هو الحال في الشبكات العصبونية التقليدية.

10. **(Pooling)** : يُستخدم لتحسين أداء الشبكة عن طريق تقليل حجم البيانات وتقليل التشوش والضوضاء في البيانات، ويتم ذلك عن طريق تجميع القيم المتعلقة ببعض العصبونات في طبقة معينة وتحويلها إلى قيمة واحدة.

2.2 الشبكات العصبية العميقة

تُعد الشبكات العصبية العميقة (Deep Neural Networks – DNN) من أبرز التقنيات التي أحدثت نقلة نوعية في مجالات الذكاء الاصطناعي. وهي بنى حسابية مستوحاة من الدماغ البشري، تتكون من طبقات متعددة من العقد (Neurons) القادرة على تمثيل الأنماط المعقدة في البيانات. وقد أثبتت فعاليتها في مهام متعددة مثل تصنيف الصور، التعرف على الكلام، والترجمة الآلية.

2.3 الشبكات الالتفافية (CNN)


تمثل الشبكات الالتفافية (Convolutional Neural Networks – CNN) حجر الأساس في معالجة الصور، إذ تقوم على تطبيق مرشحات (Filters) لاستخراج الخصائص المكانية مثل الحواف، الزوايا، والقوام. مع تراكم الطبقات، تتشكل تمثيلات عالية المستوى قادرة على توصيف محتوى الصورة. وقد شكلت CNN المكوّن الأساسي لمعظم النماذج الأولى في توصيف الصور مثل نموذج **Show and Tell**.

2.4 الشبكات المتكررة (RNN)

تُستخدم الشبكات المتكررة (Recurrent Neural Networks – RNN) لمعالجة البيانات المتسلسلة مثل النصوص. وتتميز بقدرتها على الاحتفاظ بالمعلومات السابقة ضمن الحالة المخفية (Hidden State) إلا أنّ هذه البنية تعاني من مشكلات "انفجار التدرجات" و"اضمحلال التدرجات"، مما صعب تدريبها على تسلسلات طويلة. لذلك جرى تطوير نماذج محسنة مثل LSTM وGRU، والتي استُخدمت على نطاق واسع في توصيف الصور إلى جانب CNN.

2.5 آلية الانتباه (Attention Mechanism)

ظهرت آلية الانتباه لتتيح للنموذج التركيز على أجزاء محددة من المدخلات عند إنتاج المخرجات. في سياق توصيف الصور، مكّنت هذه الآلية من ربط كل كلمة في الجملة بأجزاء مختلفة من الصورة، كما في نموذج **Show, Attend and Tell**. وقد أسهمت آلية الانتباه في تحسين جودة النصوص المولدة بشكل ملحوظ، ومهدت الطريق لظهور بنية المحولات.




الشكل 2.1: آلية الانتباه

2.6 بنية المحول (Transformer)

قدمت ورقة (Vaswani et al., 2017) **Attention Is All You Need** نموذج المحول (Transformer) كبديل عن البنى المتكررة. يقوم المحول على مفهوم الانتباه الذاتي (Self-Attention) الذي يسمح للنموذج بتمثيل العلاقات بين جميع عناصر التسلسل بشكل متوازي. يتكون المحول من قسمين رئيسيين:

- **Encoder:** يحول المدخلات إلى تمثيلات سياقية غنية.
- **Decoder:** يولد المخرجات كلمة بكلمة بالاعتماد على التمثيلات الناتجة عن الـ Encoder.

تتميز هذه البنية بقدرتها العالية على الاستفادة من التوازي الحاسوبي والتعامل مع تسلسلات طويلة.




الشكل 2.2: بنية المحول (Transformer)

2.7 المحولات البصرية (Vision Transformer – ViT)

تم اقتراح المحولات البصرية (Dosovitskiy et al., 2020) كطريقة لمعالجة الصور من خلال تقسيمها إلى رقع (Patches) صغيرة تُعامل كتسلسلات مشابهة للكلمات في النصوص. يُطبق على هذه الرقع ترميز وضعي (Positional Embedding)، ثم تُمرر عبر طبقات المحول للحصول على تمثيل شامل لمحتوى الصورة.

أثبتت ViT كفاءتها في عدد من مهام الرؤية الحاسوبية، مما جعلها خياراً مناسباً لبناء وحدة Encoder ضمن إطار توصيف الصور.



الشكل 2.3 : المحولات البصرية (Vision Transformer – ViT)

2.8 الترميز النصي باستخدام GPT-2 Tokenizer

لتحويل التعليقات النصية إلى تمثيلات رقمية، تم استخدام GPT-2 Tokenizer المدمج مع النموذج `nlpconnect/vit-gpt2-image-captioning`.

يقوم هذا الترميز بتقطيع النصوص إلى وحدات فرعية (Subwords) وتحويلها إلى معرفات رقمية (Token IDs) بطل ثابت باستخدام Padding و Truncation.

هذه التمثيلات يتم تمريرها إلى Decoder في نموذج VisionEncoderDecoder لتوليد الوصف النصي المناسب للصورة..

GPT token encoder and decoder

Enter text to tokenize it:

The dog eats the apples
El perro come las manzanas
片飯名


464 3290 25365 262 22514 198 9527 583 305 1282 39990 582 15201 292 198 31965
229 20015 106 28938 235
21 tokens

The dog eats the apples
El perro come las manzanas
片飯名

الشكل 2.4 : الترميز النصي باستخدام GPT-2 Tokenizer

2.9 خوارزمية Beam Search

تُعد خوارزمية **Beam Search** من أكثر الطرق شيوعاً لتحسين جودة النصوص المولدة. بدلاً من اختيار الكلمة الأكثر احتمالاً في كل خطوة (Greedy Search)، تقوم Beam Search بالاحتفاظ بعدة مسارات محتملة (Beams) وتوسيعها تدريجياً، ثم اختيار أفضل مسار في النهاية. هذا يتيح توليد جمل أكثر دقة واتساقاً من حيث المعنى.



الشكل 2.5 : خوارزمية Beam Search

2.10 الخلاصة النظرية

من خلال استعراض التطورات السابقة يتضح أن الانتقال من CNN+RNN إلى Transformer+ViT يمثل تطوراً طبيعياً لمواجهة التحديات المرتبطة بالتمثيل البصري واللغوي معاً. ومن هنا، يستند المشروع الحالي إلى هذه البنى المتقدمة لتحقيق أداء أفضل في توصيف الصور.

الفصل الثالث: القسم العملي

3.1 المقدمة العملية

يستعرض هذا الفصل الجوانب التطبيقية للمشروع، ابتداءً من إعداد البيئة والبيانات، مرورًا بمرحلة المعالجة المسبقة، وصولاً إلى استخدام نموذج **Vision Encoder-Decoder** مدرب مسبقًا على بيانات مشابهة (Pretrained Model) وتحسين أدائه عبر الضبط الدقيق (Fine-Tuning) على مجموعة بيانات **COC** 2017.

وقد تم اتباع خطوات منهجية منظمة لضمان إمكانية إعادة التجارب والتحقق من النتائج، مع التركيز على الاستفادة من قوة النماذج الجاهزة لتقليل وقت التدريب وتحسين جودة المخرجات.

3.2 إعداد البيئة وتنصيب المكتبات

تم إعداد بيئة العمل باستخدام PyTorch و TorchVision لتدريب ومعالجة الصور، بالإضافة إلى مكتبة Transformers من HuggingFace لبناء نموذج الـ VisionEncoderDecoder.

كما تم استخدام مكتبات مساعدة مثل:

* pycocotools لتحميل وقراءة بيانات COCO.


* Nltk لمعالجة النصوص.

* evaluate و rouge_score و datasets لحساب مقاييس التقييم مثل BLEU و ROUGE و METEOR.

```
pip install evaluate rouge_score nltk pycocotools transformers datasets --quiet!
```

3.3 تحميل وإعداد البيانات

اعتمد المشروع على **COCO 2017** بنسختي التدريب (118k) صورة (والتحقق 5k) صورة. (تم تنظيم الملفات في مسارات واضحة داخل مجلد `coco_data`، مع إنشاء مجلدات للصور والتعليقات (annotations) قمنا بأخذ جزء من بيانات التدريب وجزء من بيانات التحقق، وذلك نظراً لعدم توفر وحدات حساب كافية على موقع `colab` كما تم تخصيص مجلد منفصل لصور الاختبار وملف JSON يحوي التعليقات بالصيغة الموحدة. **COCO**



الشكل 3.1: عينات من بيانات COCO 2017 مع تعليقات مرجعية متعددة.

3.4 المعالجة المسبقة


شملت المعالجة خطين أساسيين:

3.4.1 معالجة الصور:

- * تغيير حجم الصور إلى 224×224 بكسل.
- * تطبيق قلب أفقي عشوائي (RandomHorizontalFlip) بنسبة 50% أثناء التدريب لزيادة تنوع البيانات.
- * تحويل الصورة إلى Tensor قيم بين 0 و 1

3.4.2. معالجة النصوص:

- * استخدام **GPT-2 AutoTokenizer** من نموذج (nlpconnect/vit-gpt2-image-captioning) لتجزئة التعليقات.
- * تفعيل الحشو (Padding) والتقصير (Truncation) بطول أقصى 32 توكن.
- * اختيار تعليق عشوائي واحد من كل صورة باستخدام random.choice.



الشكل 3.2: مخطط لأنبوب المعالجة المسبقة

3.5 بناء مجموعة البيانات و DataLoader

تم إنشاء مجموعتي التدريب والتحقق باستخدام torchvision.datasets.CocoCaptions. وقد جرى تمرير الصور عبر **DataLoader** باستخدام حجم دفعة (Batch Size = 8) وعدد عمال

```
(num_workers = 2) لتسريع عملية التحميل
Number of training samples: 50000
Number of validation samples: 2000

---- DataLoader Train ----
Image tensor shape: torch.Size([8, 3, 224, 224])
Number of captions: 8
Example caption: a child is playing with a ball

---- DataLoader Val ----
Image tensor shape: torch.Size([8, 3, 224, 224])
Number of captions: 8
Example caption: a dog is running on the grass
```

الشكل 3.3 :بنية بيانات COCO في PyTorch.


3.6 تصميم النموذج

تم الاعتماد على نموذج **VisionEncoderDecoder** جاهز من مكتبة HuggingFace تحت اسم **nlpconnect/vit-gpt2-image-captioning**، ويتكون من:

- **Encoder (Vision Transformer – ViT-B/16):**
 - تقسيم الصور إلى رقع (patches) بحجم 16×16 بكسل.
 - إسقاط كل رقعة إلى فضاء مخفي بحجم 768.
 - إضافة تعبئة موزعية قابلة للتعليم. (Learnable Positional Embedding)
 - تمرير التمثيلات عبر 12 طبقة Transformer متعددة الرؤوس بعدد 12 رأس
- **Attention.**
- **Decoder (GPT-2):**
 - تضمين النصوص عبر طبقة Embedding مع تعبئة موزعية قابلة للتعليم.

- تمريرها عبر 12 طبقة Transformer في الـ Decoder.
- إنتاج توزيع احتمالي على مفردات (GPT-2 حوالي 50k كلمة)

كما تم إجراء عملية ضبط دقيق (Fine-Tuning) للنموذج على مجموعة بيانات COCO 2017 بهدف تحسين دقة التوليد على هذا المجال.




الشكل 3.4: البنية المعمارية لنموذج Encoder-Decoder المعتمد.

3.7 إعداد بيئة التدريب (معدل)

- المُحسّن: تم استخدام AdamW بمعدل تعلم منخفض يساوي $2e-6$ لضمان استقرار عملية الضبط الدقيق.
- **جدولة معدل التعلم**: تم تطبيق جدولة CosineAnnealingLR لتخفيض معدل التعلم تدريجيًا مع تقدم التدريب.
- **عدد الحقبات**: تم التدريب لعدد 6 حقبات على مجموعة بيانات COCO 2017.
- **الخسارة**: النموذج يحسب خسارة CrossEntropy مع أقنعة الحشو تلقائيًا (padding mask) أثناء التدريب.

• التقنيات المساندة:

- **Mixed Precision Training** عبر `torch.cuda.amp.autocast` و `GradScaler` لتسريع التدريب وتقليل استهلاك الذاكرة.
- **Gradient Accumulation** كل 4 خطوات لتدريب فعال مع حجم دفعات صغير.
- **Data Augmentation** عبر قلب الصور أفقيًا باحتمالية 0.5 لتحسين التعميم.



الشكل 3.5: إضافة الترميز الموضعي للرقع داخل Encoder.

3.8 حلقة التدريب والتحقق



اتبعت الحلقة التدريبية الخطوات التالية:

1. تحميل دفعة (Batch) من الصور والتعليقات المرجعية.

2. ترميز النصوص باستخدام **Tokenizer** مع توليد **attention_mask**.
3. تمرير الصور والنصوص إلى النموذج للحصول على المخرجات.
4. حساب الخسارة باستخدام **CrossEntropy** مع أقنعة الحشو.
5. تطبيق **الانحدار العكسي (Backpropagation)** باستخدام **Mixed Precision** عبر **GradScaler**.
6. تحديث الأوزان باستخدام **AdamW** مع جدولة معدل التعلم (**CosineAnnealingLR**).
7. تسجيل خسائر التدريب وتقييم النموذج على بيانات التحقق وحساب مقاييس **BLEU** و **ROUGE** و **METEOR** والدقة.

3.9 التوليد والاستدلال

تم الاعتماد على **Beam Search** بحجم حزمة = 5 لتوليد التعليقات النصية. آلية **Beam Search** تستكشف أكثر من احتمال للجملة قبل اختيار النتيجة النهائية.



الشكل 3.6: آلية **Beam Search** في توليد النصوص.

3.10 التقييم الكمي:

تم تقييم النموذج باستخدام مقاييس كمية شاملة:


BLEU: لقياس تشابه الـ n -grams بين النص المولّد والنص المرجعي.

ROUGE-L: لقياس مدى التداخل النصي مع التركيز على أطول تسلسل مشترك.

METEOR: لقياس جودة الترجمة المولدة بناءً على التطابقات الجزئية والترتيب.

الدقة (Accuracy): محسوبة كنسبة الكلمات المشتركة بين المخرجات والمرجع على مستوى مجموعة الـ Validation.

تم تسجيل هذه القيم بعد كل حقبة ورسم منحنيات BLEU و ROUGE-L و METEOR والدقة لمتابعة تحسن النموذج تدريجياً أثناء التدريب، نلاحظ من الشكل أنهما في تناقص وذلك نتيجة البيانات القليلة وهي عبارة عن 50 ألف صورة فقط للتدريب و 2000 صورة للتحقق فقط ، وعدد الدورات هي 6 فقط ، ونلاحظ أن الـ BLEU بدء يستقر من الدورة الرابعة ومع زيادة عدد الدورات وزيادة كمية البيانات من المتوقع أن يرتفع، طبعاً وهذه من المشاكل التي تحدث في النماذج التي تتدرب على الصور لأنها تحتاج إلى قدر كبير من البيانات وعدد دورات كبير .



الشكل 3.7: منحنيات BLEU و ROUGE عبر الحقبات.

3.11 حفظ واسترجاع النموذج

حفظ واستئناف التدريب (Checkpointing)

تم تصميم آلية متكاملة لحفظ نقاط التحقق (Checkpoints) تلقائياً عند الحصول على أفضل أداء على بيانات التحقق (Validation). حيث يتم حفظ:

* حالة النموذج (Model Weights) باستخدام save_pretrained.
* حالة المحسن (Optimizer) والـ Scheduler في ملف مستقل لضمان استئناف عملية التدريب بنفس حالة التعلم.


* رقم الحقبة وأفضل قيمة لخسارة التحقق (Val Loss) إضافة إلى القيم التاريخية للمقاييس BLEU ، ROUGE ، METEOR ، Accuracy في ملف JSON
عند إعادة تشغيل التدريب، يقوم الكود تلقائياً بتحميل هذه الملفات لاستئناف التدريب من آخر نقطة توقف بدون فقدان التقدم السابق.

3.12 نتائج التدريب والتحقق:

نلاحظ من النتيجة التي أماننا أنها مقبولة رغم تناقص المقاييس على كامل الدورات ، ونلاحظ من الشكل 3.10 أن الـ va_loss تتناقص وهذا يدل على أنه يتدرب جيداً، بينما الـ accuracy في البداية كانتا مرتفعة وبعدها تناقصت بسبب قلة تتطابق الكلمات بين الجمل المولدة والجمل المرجعية.




الشكل 3.8: نتيجة بعد التدريب والتحقق



الشكل 3.9: منحنيات loss و accuracy

3.13 نتائج الاختبار

قمنا بتحميل بيانات خارجية تحوي على صور و 5 جمل وصفية لكل منها بعد الانتهاء من التدريب قمنا باختبار النموذج على هذه البيانات وكانت النتائج كالتالي:



الشكل 3.10: نتائج الاختبار

3.14 الخاتمة العملية

أظهر هذا القسم أن الجمع بين **Vision Transformer** و **Text Transformer** عبر بنية Decoder_Encoder يوفر قدرة عالية على توليد تعليقات دقيقة نوعاً ما وذات معنى للصور. ورغم تحديات حجم البيانات وتكلفة التدريب، فقد بيّنت النتائج الكمية والنوعية جدوى المنهجية المقترحة كأساس لتطبيقات أوسع في فهم الصور ومعالجتها.

المراجع

- i. COCO Consortium. (2015). Microsoft COCO API (pycocotools). Retrieved from <https://github.com/cocodataset/cocoapi>
- ii. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, 4171–4186.
- iii. Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- iv. Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. *Text Summarization Branches Out: Proceedings of the ACL-04 Workshop*, 74–81.
- v. Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. *European Conference on Computer Vision (ECCV)*, 740–755. Springer.
- vi. Papineni, K., Roukos, S., Ward, T., & Zhu, W. J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, 311–318.
- vii. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems (NeurIPS)*, 8026–8037.
- viii. Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*.
- ix. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 5998–6008.
- x. Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., ... & Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38–45.
- xi. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2010.11929>